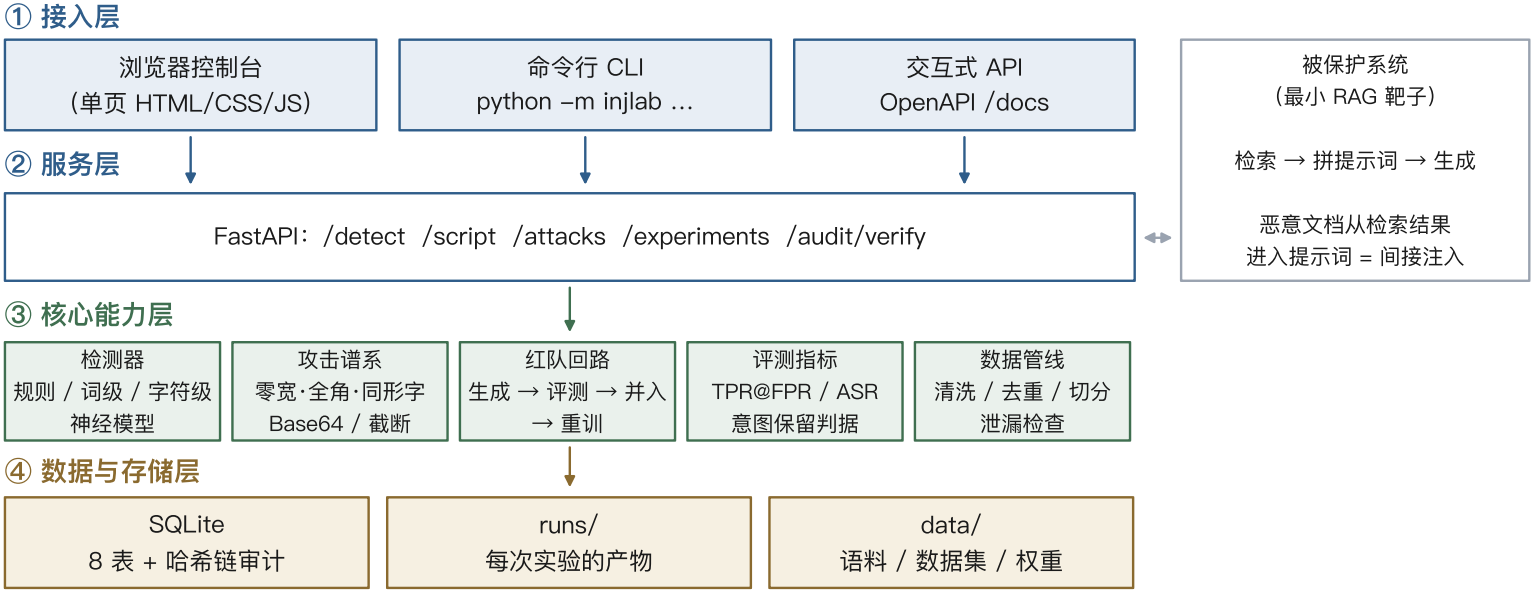


设计约束：全部离线可跑；神经模型一个进程只加载一个（峰值内存 = 最大单模型）；所有实验产物落盘可复现。

信任边界：用户输入 / 检索到的外部文档 / 工具返回 / 模型输出 —— 后三者都可能携带指令。